HW1 ASR - итоговый отчёт

13 октября 2026 года. Собственная акустическая CTC-модель обучена с нуля и дообучена на смеси clean/other. Итоговая модель и декодер выбраны по полным dev-наборам; test использован после их фиксации. Полные результаты и ошибки записаны в FINAL_RESULTS.json.

Архитектура и обработка звука

DeepSpeech2-подобная модель: две свёртки с суммарным уменьшением времени в четыре раза, пять двунаправленных GRU по 512 скрытых единиц на направление, линейный выход; 24 471 453 параметра. Вход - mono 16 кГц, 80 log-Mel полос, окно 25 мс, шаг 10 мс. Алфавит - 26 английских букв, пробел, апостроф и CTC blank. Длины после свёрток вычисляются явно; padding исключается из декодирования и CTC.

Обучение использует AdamW, warmup/cosine scheduler, clipping 5, BF16 forward и FP32 CTC loss. История обязательного шаблона example/asr сохранена в Git; новая реализация находится в src/asr. Внешние акустические веса не использовались.

Данные и последовательность обучения

Ранняя собственная цепочка: staging с нуля, основные и контрольные этапы train-clean-100, затем train-clean-100 вместе с train-clean-360, суммарно 464,196 часа clean. Конфигурации, initialization-события и неизменяемые родительские веса сохранены; ранний рецепт - REPRODUCTION.md.

Для трудной речи добавлены 100,1166 часа из train-other-500: 29 767 записей, 229 спикеров, первые полные главы в порядке официального OpenSLR-архива. Это не случайная или сбалансированная выборка. Полный исходный 500-часовой архив не скачан и не проверен целиком. Отобранные FLAC и тексты прошли SHA, полное декодирование, CTC-проверки и проверку отсутствия пересечения ID с clean/dev/test. Точные ID, тексты и хеши находятся в other100-data-provenance.zip.

Смешанное обучение шло с 17:25 до 20:40 МСК: сначала все clean 464,196 часа и other 50,068 часа с девятью повторениями; с 17:51 - все clean и other 100,1166 часа с пятью повторениями. Во втором этапе other составляет 51,886% экспозиции по длительности. Первые 50 часов входят в 100 часов, уникальных other-данных не 150 часов. На второй GPU продолжалось clean-контрольное обучение.

Выбран lr_candidate_othermix100_5x__best: step 46179, epoch 20, batch_index 2199. Родитель - закрытый best mixed50 SHA 1dcda0513cedf0039af15e13385defc3fb067e31e61053aeff35049757e94934. Mixed100 начал новый optimizer/scheduler: batch 128, accumulation 1, LR 5e-05, weight decay 0.0001, warmup 300, горизонт 40 эпох, seed 1, data_epoch_offset 240. Полная сохранённая конфигурация - FINAL_TRAINING_RECIPE.json.

Профиль effective_v2 содержит громкость с плавной огибающей, шум, изменение скорости и слабую контролируемую реверберацию; действует защита CTC-длин. Оригиналы и преобразованные WAV/спектрограммы сохранены в media каждого опыта. Legacy-режим и старые эксперименты не удалены.

Выбор модели и сравнение экспериментов

Рассмотрены best/last 14 завершённых этапов: 28 различных model-file SHA. Правило заранее утверждено: минимальный корпусный greedy WER полного dev-other при полном dev-clean ≤20%; затем dev-clean и имя. Промежуточный мониторинг dev256 не заменяет эти полные оценки. В следующей таблице у всех строк одинаковый greedy-декодер и полные dev-наборы.

Этап / checkpoint	dev-clean WER	dev-other WER
Предыдущий e640 / last	14.31014%	39.21253%
Clean LR1e-5 / best	14.13735%	38.99270%
Clean LR1e-5 / last	14.00868%	38.97503%
Clean LR3e-5 / best	14.37999%	39.14383%
Clean LR3e-5 / last	14.47373%	39.23608%
Clean + other50 ×9 / best	15.43877%	38.05449%
Clean + other50 ×9 / last	15.43877%	38.05449%
Clean + other100 ×5 / best	14.21823%	34.86300%
Clean + other100 ×5 / last	14.23661%	35.11227%

Clean-контроль почти не улучшил other; добавление трудной обучающей речи снизило полный dev-other с 39,21253% до 34,86300% greedy при близком clean. Это последовательные эксперименты с разными длительностью и scheduler, поэтому таблица не доказывает изолированный причинный эффект одного изменения. Все 28 оценок, включая прежние augmentation/legacy кандидаты, сохранены в FINAL_RESULTS.json.

Декодирование и фиксация до test

Для выбранной модели по обоим полным dev-наборам проверены 13 настроек: greedy, собственный CTC prefix beam ширины 10/20/50, те же beam с LM weights 0.1/0.2/0.3, word bonus 1, token_topk 8. Выбран beam50 + LM 0.1 по dev-other с ограничением clean. LM - официальная LibriSpeech 3-gram OpenSLR 11; ARPA fusion реализован в собственном декодере. Это внешний языковой ресурс, а не акустическая модель.

Модель зафиксирована 20:45:22, декодер - 20:53:54; итоговая test-оценка завершена 20:56:31 МСК. Настройки после test не менялись.

Полные итоговые метрики

WER = сумма word errors / сумма reference words; CER аналогично по символам. Поднабор dev256 сюда не входит.

Набор	Записей	WER	CER	Ошибки / слова
dev-clean	2703	13.42230%	4.30083%	7302 / 54402
dev-other	2864	33.36932%	13.75141%	17001 / 50948
test-clean	2620	13.55181%	4.28800%	7125 / 52576

Набор	Записей	WER	CER	Ошибки / слова
test-other	2939	35.46797%	14.54513%	18565 / 52343

На одной замороженной модели сравнение декодеров на test (настройки заранее выбраны по dev):

Декодер	test-clean WER	test-other WER
Greedy	14.27457%	36.88363%
Собственный beam50 без LM	13.90368%	36.25127%
Beam50 + LM0.1	13.55181%	35.46797%

Относительно ранее сохранённой e640 модели test-other снизился с 39,88499% до 35,46797% (4,41702 процентного пункта); test-clean - с 13,97976% до 13,55181%. Это сравнение итогов после dev-выбора, а не отбор по test. Порог test-clean ≤20% достигнут; test-other ≤30% не достигнут.

Восстановление и проверка

Model-only SHA-256: e05cdea14cb642968ffa30e87373d84bb13c6ffcb6a5b08f5a4cd9da66366e4f. Full resume SHA-256: 9d4afccb97075453b9edc263c6af8d67eb7d482eac40276e5b81d792ca233fd6. Локально и на ГМЦ совпали все тензоры и состояние model/full; восстановлены AdamW, scheduler, Python/NumPy/Torch/CUDA RNG и градиенты. Диагностический FP32 CPU-шаг на четырёх настоящих коротких обучающих записях дал конечные loss 0,00685070 и gradient norm 0,807556; изменения выполнены только в RAM, сдаваемые веса не менялись.

105 тестов пройдены локально после фиксации параметров notebook; 105 тестов и pip check - в независимом чистом экспорте исходников на ГМЦ. Проверены CTC-повторы/blank/пустой результат, padding/длины, маленькие beam-примеры, корпусные метрики, форматы и sample rate/stereo, отсутствие эталонов, реальные train/resume и выбор best. Ранний реальный overfit одного батча достиг нулевых WER/CER; его логи сохранены.

Свежий Colab T4: до установки папка проекта отсутствовала, исходный ZIP и замороженный манифест скачаны анонимно с SHA. Выполнены все 12 исходных ячеек с эталонами и затем без них. С эталоном получено 3 ошибки на 36 словах одного обучающего примера - это проверка интерфейса, не benchmark. Без эталонов обработаны WAV/FLAC/MP3 с разными sample rate и stereo: ровно три исходных ID, target=null, metrics=null, отдельный каталог без старых предсказаний. Исполненные notebook, ZIP, проверки источников и снимки включаются в acceptance-final2040.zip.

Комплект и ограничения воспроизводимости

resources.json содержит анонимные URL и SHA model/example/LM. Полные закрытые логи всех этапов, offline W&B, JSONL, аудио и спектрограммы находятся отдельными ZIP в архиве воспроизведения; скачивать их для обычного инференса не требуется. evaluation2040.tar.gz содержит все сравнения кандидатов/декодеров, полные предсказания, разбор ошибок, resume и доказательство фактического выхода тренеров; все 133664 логических файла проверены по SHA.

История Git и собственные родительские веса сохранены. Восстановление выбранного этапа требует полной сохранённой cfg, а не одного resume-флага: см. RESUME_RECIPE.md. Для повторения с нуля нужно восстановить данные и пройти всю собственную последовательность

этапов; операторы получения other-поднабора содержат исходные машинные пути и требуют адаптации. Побитово одинаковая траектория на другом устройстве или batch не обещается.

Git bundle и SHA-архив - согласованный резервный способ передачи при недоступной публикации GitHub. Notebook устанавливается по проверенному анонимному ZIP и не зависит от авторизации репозитория. Финальные хеши архива и commit находятся в delivery manifest; доказательство его восстановления хранится отдельно, чтобы не создавать циклический хеш.

Правила курса запрещают использование LLM. Работа подготовлена с AI-помощью; техническая воспроизводимость не подтверждает соответствие этому правилу.

Графики ниже показывают измеренные журналы четырёх дополнительных этапов. Их dev-кривые относятся к фиксированным поднаборам 256 записей; итоговые полные dev/test метрики приведены только в таблицах выше.

Кривые из локальных журналов

Источник: control-lr1e5\metrics.jsonl, control-lr3e5\metrics.jsonl, mixed50\metrics.jsonl, mixed100\metrics.jsonl. Только измеренные значения; пилотные запуски не заменяют итоговую оценку.

