HW1 ASR: итоговый отчёт, 14 октября 2026

Модель и данные

Собственная DeepSpeech2-CTC, 24 471 453 параметра: две свёртки 3×3 со stride 2, пять двунаправленных GRU по 512 единиц на направление, LayerNorm, dropout и линейный выход. Словарь: 26 английских букв, пробел, апостроф и CTC blank. Длина после свёрток равна ceil(T/4).

Английская речь из публичного LibriSpeech. Вход: mono 16 кГц, 80 log-Mel полос, окно 25 мс, шаг 10 мс, нормализация по записи. Обучение: 496,8569 уникальных часов train-other и 464,1965 часов train-clean. Всего 281 240 записей и 2 338 дикторов. Одна несовместимая с CTC запись исключена из обучения; исходный файл сохранён. Пересечения идентификаторов и дикторов с dev/test проверены: ноль.

Сравнивались смеси 75/25 и 85/15 other/clean по длительности с повторением other и сохранением clean replay. Итоговая модель - last варианта 85/15. Повторы не считаются новыми уникальными часами. Точные manifests, проверки и исходные рецепты включены в архив.

Обучение и ускорение

AdamW, BF16 forward, CTC в FP32, clipping 5, batch 256, восемь workers, prefetch 1. В финальных этапах LR 3e-5, warmup 300, фиксированный cosine scheduler; возобновление сохраняло optimizer, scheduler и RNG. Пять GRU обрабатывают PackedSequence без повторного распаковывания между слоями. Есть группировка записей по длине и пропуск уже обработанных записей при resume.

Аудиоаугментации: плавное изменение громкости, шум, изменение скорости и контролируемая слабая реверберация. Дополнительно мягкий SpecAugment только при обучении: две частотные маски до восьми полос и две временные маски до min(40 кадров, 5% длины). Аугментации при оценке отключены.

Наблюдаемая производительность выросла с 6 463,97 до 7 526,31 аудиочаса за час, на 16,43%. Это сравнение рабочих запусков, а не чистая причинная абляция. GPU Mel проверялся отдельно, но не включён в итоговую цепочку. Все этапы завершены штатно после cutoff 16:00 МСК; итоговые шаги двух тренеров - 75 013 и 74 028.

Выбор модели и декодера

112 уникальных моделей сравнивались по полным dev-наборам. Критерий: минимальный dev-other WER при dev-clean WER ≤20%, затем dev-clean и имя. Декодер выбран среди 13 вариантов на dev. Итог: собственный prefix beam search, beam 50, token_topk 8, внешняя 3-gram LM с весом 0,1 и word bonus 1. Модель и декодер зафиксированы до итоговой оценки test; настройки по итоговому test не менялись.

Полные итоговые метрики

WER и CER корпусные: сумма расстояний редактирования, делённая на суммарное число слов или символов. Все четыре набора оценены полностью.

Набор	WER, %	CER, %	Ошибки / слова	Записи
dev-clean	12.20911	3.86991	6642 / 54402	2703
dev-other	28.19934	11.19943	14367 / 50948	2864
test-clean	12.12721	3.79640	6376 / 52576	2620
test-other	29.38120	11.61103	15379 / 52343	2939

Ориентиры WER ≤20% test-clean и ≤30% test-other достигнуты. Это измеренные результаты, а не гарантия оценки курса.

Эффект декодирования на одной модели

Декодер	Полный dev-clean WER, %	Полный dev-other WER, %
Greedy	12,96460	29,78331
Beam 10	12,51976	29,14737
Beam 50	12,52527	29,13166
Beam 50 + LM 0,1	12,20911	28,19934

Beam 50 исправил 332 дополнительных word errors на dev-other по сравнению с greedy. LM исправила ещё 475. Всего улучшение составляет 807 ошибок, или 1,584 процентного пункта. Last смеси 75/25 имеет greedy dev-other 29,78920%, last 85/15 - 29,78331%; разница всего три ошибки и не доказывает устойчивого превосходства доли 85%.

Анализ графиков финальных запусков

В конце отчёта приложены четыре графика из закрытых JSONL финальных этапов 75/25 и 85/15: CTC loss, LR, норма градиента до clipping и продвижение optimizer steps по времени. Для loss показаны исходные точки и скользящая медиана; в этих графиках нет subset-WER. Все показатели качества выше относятся только к полным наборам.

Медиана loss первых/последних 100 записанных шагов снизилась с 0,33452 до 0,28579 для 75/25 и с 0,33888 до 0,29139 для 85/15. Колебания отдельных батчей сохраняются из-за разной сложности аудио и аугментаций; сравнение сырых loss между смесями не заменяет dev-отбор. LR плавно снизился с 2,96e-5 до 3,01e-6 и с 2,93e-5 до 4,97e-6 соответственно. Редкие нормы до clipping достигали 24,07 и 57,64; перед optimizer step применяется clipping5. Значения конечны, пики не скрыты на логарифмической шкале.

Оба этапа начались с сохранённого full resume, поэтому график optimizer step начинается не с нуля. Предыдущие этапы и журналы с первоначальной инициализации сохранены в компонентах полного архива. Периоды валидации и checkpoint входят в фактическое прошедшее время. Выигрыш нового состава смеси не следует выводить по тренировочному loss: по полному greedy dev-other два last-кандидата отличаются всего тремя ошибками.

Ошибки и проверка

На полном test-other: 12 932 замены, 1 234 удаления, 1 213 вставок. Часто путаются короткие служебные слова: the/a, and/in. Примеры и предсказания всех записей находятся в оценочном архиве. Сложные записи и имена собственные остаются источником ошибок.

Model-only и matching full checkpoint проверены по всем тензорам. Состояния optimizer/scheduler/RNG проверены; диагностический backward выполнен отдельно без изменения сдаваемых весов. Цепочка родителей и все закрытые логи сохранены. CPU проверки: 181 passed, два Windows symlink теста пропущены. Окончательный12-ячеечный Colab дополнительно выполнен в свежей CPU-сессии с эталонами и без них; прежние успешные T4 proofs сохранены. Новая GPU-сессия отклонена лимитом аккаунта, а не ошибкой ASR. Чистая установка и восстановление source bundle проверены.

В свежем Colab с Tesla T4 выполнены установка, загрузка ресурсов и инференс итоговой модели. Отдельно проверены набор с эталоном и набор без эталонов: три исходных ID сохранены, metrics=null, файл ложных метрик отсутствует. Вложены выполненные notebooks, ZIP предсказаний, SHA и скриншоты. Клиентский files.download в браузере требует доступного output-frame; альтернативно готовый ZIP находится в панели Файлы. Байты фактических результатов независимо проверены. Окончательная привязка source/notebook фиксируется в ACCEPTANCE.md.

Воспроизведение и ограничения

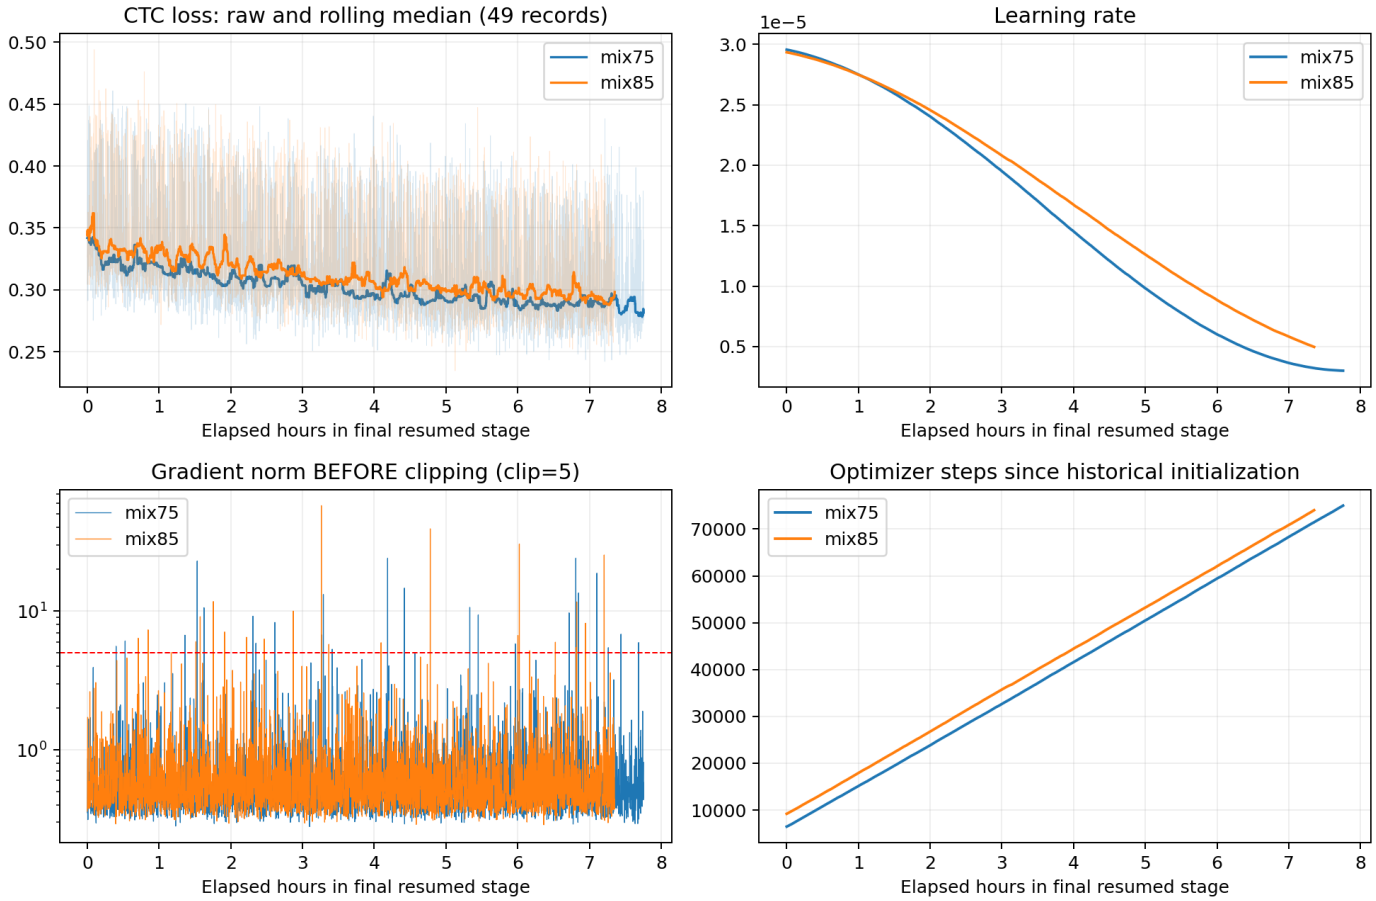
Начните с ARCHIVE_README.md. source.zip содержит полный исходный проект; source.bundle - историю Git и именованную ветку. model.pt - веса, resume.pt - полный checkpoint. resources.json фиксирует веса, LM и декодер. Полные manifests, закрытые логи, родительские состояния и результаты оценки сохранены отдельными вложенными архивами. Исходный аудиокорпус LibriSpeech скачивается отдельно; весь аудиокорпус в сдаваемый архив не включён.

Данные other сначала использовались как фиксированный префикс по целым главам, затем подключён полный проверенный набор. Это не случайная выборка. Несколько параметров менялись между ранними этапами, поэтому результаты этих этапов не названы чистой абляцией.

В инструкции курса указан прямой запрет LLM. Работа подготовлена с помощью LLM; техническая воспроизводимость не означает соблюдения этого правила. Архив и Git bundle предоставляются вместе с исходниками. Текущий подтверждённый статус публикации GitHub и анонимного клонирования указан в ACCEPTANCE.md.

Final training stages: measured closed logs

75/25 and 85/15 other/clean. Full resume; no quality claims from train loss.



Source: two original metrics.jsonl files, copied with SHA-256 verification.

Validation/checkpoint pauses are included in elapsed wall time.

Final full-set WER/CER and decoder comparison are in the preceding tables.