ДЗ-1 ASR - рабочий отчёт

Состояние: обучение и итоговая оценка ещё не завершены. Дедлайн: 13 октября 2026 года, 16:00 МСК. Приведённые ниже пилотные проверки не являются результатом сдаваемой модели.

Задача и реализация

Реализован собственный распознаватель английской речи с CTC loss. Проект основан на обязательном шаблоне курса example/asr; история шаблона сохранена в Git. Скачанные акустические модели и сторонние реализации ASR не использовались.

Вход преобразуется в mono 16 кГц и 80 log-Mel полос с окном 25 мс и шагом 10 мс. Две свёртки 3×3 со stride 2 уменьшают временную ось в четыре раза. Далее следуют пять двунаправленных GRU с 512 скрытыми единицами на направление и линейный выход на 29 символов: CTC blank, 26 букв, пробел и апостроф. Модель содержит **24 471 453 параметра**. Для последовательности длины L выходная длина равна ceil(L/4); padding маскируется до свёрток и между ними.

Обучение использует AdamW, LR 3e-4, warmup и cosine decay, clipping 5 и BF16 с вычислением log-softmax и CTC loss в FP32. Записи группируются по длине. Четыре аудиоаугментации: громкость, аддитивный шум, изменение скорости и слабая реверберация. Примеры аудио и спектрограмм сохраняются отдельно.

Данные и выбор модели

Основной корпус - LibriSpeech train-clean-100. Фиксированные train-фрагменты из 96 и 1024 записей позволяют проверить и запустить цепочку до завершения передачи полного корпуса. Источник, идентификаторы и конфигурации каждого запуска сохраняются. Дополнительный train-clean-360 передан, проверен по SHA-256 и распакован в 05:43:45 МСК до cutoff 06:00. Подготовлены 104014 записей (363,61 часа); вместе с train-clean-100 это 132553 записи, 464,20 часа. Полная проверка заголовков и CTC-длин обоих train-наборов не выявила пропусков, дубликатов или невозможных выравниваний. Минимальный запас выходных CTC-шагов равен 6 на train100 и 2 на train360.

Dev-clean и dev-other используются для выбора checkpoint и параметров декодирования. Test-clean и test-other предназначены для однократной итоговой оценки выбранного варианта. Корпусные WER/CER вычисляются как сумма расстояний редактирования, делённая на суммарное число слов/символов эталонов.

Размер батча

На второй H200 измерены forward/backward и шаг AdamW на фиксированных реальных train-записях с BF16: batch 32/64/128/256 даёт 310/495/579/621 записей в секунду и использует 1,83/3,28/6,22/12,12 GiB peak allocated памяти. Измерение включает два прогревочных и восемь учитываемых шагов; загрузка аудио не включена, поэтому это не время полной эпохи. Временные веса замера не используются как модель качества.

Основной запуск сохраняет batch 32 и LR 1e-4 для следующего этапа. Второй кандидат использует batch 128 и LR 3e-4. Это сравнение конфигураций по dev, а не изолированная абляция LR или размера батча.

Эксперименты и проверки

Проверка	Фактический результат	Значение
Переобучение четырёх реальных train-записей на H200	WER 0, CER 0 на шаге 81	Проверка способности модели обучаться; не оценка обобщения
Пилот: 96 train-записей, 300 шагов	Цепочка обучения завершилась, конечный loss конечен	Проверка логов, checkpoint и инференса
Декодеры пилота, восемь dev-clean записей, одна модель	Greedy: 170/154 словесных ошибок; beam 10: 169/154	Техническая проверка сравнения; непригодно для оценки итогового качества
Проверки кода	Все 45 тестов прошли локально	CTC, beam против полного перебора, padding, метрики, форматы аудио, resume
Чистое окружение без сети и унаследованных пакетов	Установка, pip check, 45 тестов и CPU-инференс четырёх записей прошли	Проверка воспроизводимости окружения; не свежий Colab
Основное обучение	60 эпох на train-clean-100 завершены; с 06:00 обучение на 132553 записях train100+360	По 256 контрольных записей; промежуточные значения
Без аугментаций	8920 шагов: WER dev-clean 38,33%, dev-other 64,79%	Сравнение с аугментациями на том же шаге и тех же записях: clean 35,82% против 38,33% без аугментаций
Свежий Colab, Tesla T4	Установка, 23 теста, greedy/beam и метрики выполнены	Исходники и пилотные веса загружены вручную; полный demo с финальными ссылками ещё предстоит

WER может превышать 100%, поскольку вставки также входят в число ошибок. Значения пилота намеренно не представлены как достижение целевых порогов.

Промежуточная оценка на полных dev-наборах

Сохранённая модель ровно 8920 шагов использована для всех строк ниже. SHA-256: 5c264b2d21e7ea92578de2a9612290fda372602f2b46023ee979e1b0485f38cf. Вероятности закешированы один раз, все декодеры получают одинаковые записи. Это промежуточная модель, а не выбранная финальная сдача.

Набор	Декодер	Записей	WER	CER	Ошибок/слов
dev-clean	greedy	2703	35.73%	11.70%	19437/54402
dev-clean	beam20	2703	34.89%	11.39%	18982/54402
dev-clean	beam20_lm0.1_bonus1.0	2703	33.73%	11.30%	18351/54402
dev-other	greedy	2864	60.75%	26.32%	30950/50948
dev-other	beam20	2864	60.05%	25.91%	30596/50948
dev-other	beam20_lm0.1_bonus1.0	2864	58.87%	25.86%	29993/50948

Beam реализован самостоятельно как CTC prefix search с отдельными вероятностями blank/nonblank в логарифмической области. Внешняя LM - публичная прореженная триграмма OpenSLR, без акустических весов. Для приведённого варианта вес LM равен 0.1, word bonus равен 1.0; более высокие веса 0.3/0.5 ухудшали clean на фиксированном dev-фрагменте. Финальные параметры будут повторно выбраны на dev для окончательного checkpoint.

Аугментации: 60 эпох на полном dev

Оба запуска имеют одинаковые исходные веса собственного staging-этапа, seed, train-clean-100, batch 32, LR schedule и 53520 шагов обучения. Зафиксированы именно last-модели после 60 эпох; checkpoint не выбирался отдельно для каждой строки. Отличие - включение четырёх аугментаций. Оценены все 2703 записи dev-clean и 2864 dev-other с greedy.

Набор	С аугментациями WER	Без аугментаций WER	С аугментациями CER	Без аугментаций CER
dev-clean	24.45%	28.82%	7.98%	9.89%
dev-other	51.38%	57.89%	22.21%	26.06%

Аугментации снизили WER на 4,37 процентного пункта для clean и 6,51 для other. Это результат двух конкретных запусков с одним seed; оценка вариативности между seed не проводилась. Хеши моделей, конфигурации, транскрипции и суммы ошибок сохранены в ablation-60epoch и локальных JSON-результатах. Эти dev-результаты не подменяют итоговую оценку выбранной модели на test.

Структура ошибок промежуточной модели

Для той же last-модели после 60 эпох выполнено словесное выравнивание всех dev-предсказаний. Суммы замен, пропусков и вставок точно совпали с числителем корпусного WER.

Набор	Замены	Пропуски	Вставки	Всего ошибок / слов
dev-clean	11145	1055	1101	13301 / 54402
dev-other	22005	2236	1936	26177 / 50948

Около 84% словесных ошибок составляют замены. Среди частых пар встречаются in → and и and → in; часты вставки и пропуски коротких служебных слов. Это абсолютные частоты, а не вероятность ошибки для данного слова: для такого вывода нужна нормировка на число его употреблений. В отдельных записях видны ошибки границ слов (inevitable → in evitable) и орфографии; на other встречаются длинные сильно искажённые фрагменты. Эти наблюдения относятся к сохранённым dev-предсказаниям, а не к оценке причин по прослушиванию.

При равных минимальных расстояниях выбран порядок diagonal/deletion/insertion; разложение S/D/I зависит от разрешения таких равенств, общий WER - нет. Скрипт scripts/analyze_errors.py сохраняет частые пары и пять примеров с наибольшим абсолютным числом словесных ошибок (UID разрешает равенства). Финальный анализ будет повторён для выбранной модели.

Последний промежуточный снимок декодирования

Снимок основной модели сохранён на шаге 42816 (эпоха 47), SHA-256 9c9cc9ec7d63d5d951e5a931af305dd583b38507945c4c705376d413a8ca8d48. Проверены 13 настроек на 256 случайных записях каждого dev-набора с seed 42. Это отдельный фиксированный поднабор, отличающийся от мониторинга обучения с seed 1; строки относятся к одним и тем же вероятностям снимка.

Набор	Greedy WER	Beam10 WER	Beam10 + LM 0.2 WER	CER с LM
dev-clean, 256 записей	25.81%	25.34%	24.50%	8.05%
dev-other, 256 записей	51.73%	51.47%	49.90%	22.32%

Word bonus равен 1.0. Для этого поднабора минимальный суммарный корпусный WER дала ширина 10 с весом LM 0.2. Это предварительная проверка; окончательный декодер выбирается заново на обоих полных dev-наборах после фиксации модели. Test-наборы здесь не использовались.

Обнаруженные ошибки и исправления

Первый диагностический контейнер не предоставлял CUDA, поэтому проверка шла на CPU. Для отдельного учебного контейнера применён режим, при котором доступ к обеим H200 подтверждён реальным вычислением. Остальные сервисы и Xorg не изменялись; аппаратный reset не требовался для обучения.

Ревью выявило потерю накопленных градиентов в checkpoint между шагами оптимизатора. Теперь checkpoint сохраняет сами градиенты и число обработанных microbatch. Регрессионный тест сравнивает следующий шаг непрерывного и восстановленного обучения с dropout и частичным накоплением: параметры и следующий RNG draw совпадают точно. Аугментации детерминированы по seed, эпохе и индексу записи; DataLoader использует отдельный генератор. При изменении batch после OOM текущая эпоха явно начинается заново. При исключении сохраняется последний исправный checkpoint, а не повреждённое состояние.

При изменении скорости одна быстрая запись получала 162 выходных шага при необходимых 164, и обучение явно остановилось. Проверка всех исходных 28 539 записей не выявила невыполнимых выравниваний. Минимальная длина ускоренной записи теперь ограничена длиной текста с учётом повторяющихся символов; отдельный тест воспроизводит проблему и проверяет исправление. Обучение восстановлено из исправного checkpoint и прошло проблемный шаг.

Управление этапами исправлено отдельно: повторное resume уже законченных 60 эпох больше не используется как продолжение кампании. Если первый этап заканчивается раньше 06:00, запускается refinement с новым scheduler. После 06:00 запускается новый этап на 460 или 100 часах, ограниченный 12:30; инициализация выбирается по dev среди сохранённых основных кандидатов. Тесты проверяют продолжение и строгое время готовности дополнительных данных.

Независимый контроллер итоговой оценки ожидает 12:30. Он фиксирует best-модель каждого этапа, выбирает checkpoint по greedy WER полного dev-clean, затем декодер - по суммарным ошибкам и словам обоих полных dev-наборов. До этой фиксации test не оценивается. Проверяется совпадение всех тензоров и состояния модели с полным resume-checkpoint. Ревью

выявило неатомарную запись снимков и кешей; прерывание теперь восстанавливается через проверку файла и повторное построение, записи завершаются атомарным переименованием.

Для обучения на 460 часах выделено отдельное окно 06:00-12:30. Если дополнительный корпус не готов вовремя, основное обучение на 100 часах продолжается. Сбой W&B не останавливает запись локальных JSONL.

Воспроизведение

Команды установки, обучения, возобновления, инференса и расчёта метрик приведены в README. Каждый запуск сохраняет config.json, train_manifest.json, metrics.jsonl, offline W&B, best/last checkpoint и модель для безопасной загрузки weights_only=True. scripts/evaluate_decoders.py сохраняет вероятности одной модели и сравнивает greedy с собственным prefix beam на одинаковых записях.

Перед сдачей сюда будут добавлены: точный выбранный checkpoint и SHA-256, финальные конфигурации, измеренные dev/test метрики, сравнение аугментаций и beam, ссылки на ресурсы, результат чистой установки и свежего Colab, состав архива.

Ограничения

Целевые WER ≤20% на test-clean и ≤30% на test-other пока не подтверждены. Notebook подготовлен, но его полный запуск в свежем Colab с финальными ресурсами ещё не выполнен. Репозиторий должен оставаться приватным до дедлайна. Правила курса запрещают LLM: техническая готовность этой работы не подтверждает соответствие этому правилу.

Кривые из локальных журналов

Источник: logs\current-main-metrics.jsonl, logs\current-noaug-metrics.jsonl. Только измеренные значения; пилотные запуски не заменяют итоговую оценку.

