ДЗ-1 ASR - рабочий отчёт

Состояние на 14:05 МСК: первая полная итоговая оценка завершена. Сохранённый кандидат даёт WER 14,17% на test-clean и 40,46% на test-other. По запросу пользователя два дополнительных этапа обучаются до 15:25; прежние веса и результаты сохранены. Их замена допустима только после выбора по полным dev-наборам и повторной приёмки. Дедлайн: 13 октября 2026 года, 16:00 МСК.

Выбор окончательного checkpoint

В 12:39 МСК зафиксирована модель lr_candidate_finetune460_continue2__last: шаг 31717, эпоха 30, batch_index 637 текущего этапа. Перед test рассмотрены best и last восьми основных запусков: 16 файлов с различными SHA-256. Каждая модель оценена на всех 2703 записях dev-clean и 2864 dev-other. Ранжирование - сумма word errors обоих наборов, делённая на сумму reference words; при равенстве - clean, other, имя кандидата. Это правило зафиксировано до test.

Этап	Checkpoint	Dev-clean WER	Dev-other WER	Объединённый WER
baseline, продолжение 2	last	14.6557%	39.6581%	26.7470%
effective_v2	best	14.7090%	39.6228%	26.7575%
effective_v2	last	14.7090%	39.6228%	26.7575%
baseline, продолжение 1	last	14.9645%	39.9289%	27.0375%
baseline, продолжение 1	best	14.9167%	39.9839%	27.0394%
baseline, продолжение 2	best	15.0601%	40.1743%	27.2055%
464 часа, batch 32	best	15.4498%	40.5099%	27.5691%
464 часа, batch 32	last	15.3652%	40.6905%	27.6127%
464 часа, batch 128	best	15.6777%	41.1537%	27.9981%
464 часа, batch 128	last	15.6777%	41.1537%	27.9981%
100 часов, аугментации	last	24.4495%	51.3798%	37.4732%
100 часов, аугментации	best	24.3263%	51.7802%	37.6032%
refinement 100 часов	best	25.3612%	52.0806%	38.2829%
refinement 100 часов	last	25.4439%	52.0943%	38.3322%
100 часов, без аугментаций	best	28.8427%	57.7726%	42.8334%
100 часов, без аугментаций	last	28.8151%	57.8884%	42.8752%

Выбранный baseline даёт 7973/54402 word errors на dev-clean и 20205/50948 на dev-other. У ближайшего effective_v2 - 8002 и 20187: на объединённых 105350 словах baseline сделал на 11 ошибок меньше. Это очень небольшая разница; самостоятельное преимущество исправленных аугментаций по этому сравнению не установлено. Для сдачи сохранён вариант, победивший по заранее принятому правилу.

SHA-256 model-only: d919aed41505686fe2e590b6253defc4283585c02cc35ac0e368c72fd534679f, 97898508 байт. SHA-256 соответствующего full checkpoint: 578761bf43375569315db9e62d5a0ef70554b84b2413bb151967c2da6a3152b2, 293733233 байта. Обе копии скачаны на E, хеши сверены с ГМЦ, все тензоры и состояние совпали. Выбор по суммам ошибок независимо пересчитан после скачивания.

Для этого full checkpoint проверено точное восстановление параметров, AdamW, scheduler, Python/NumPy/Torch/CUDA RNG и сохранённых градиентов. Диагностический FP32 CPU-шаг на четырёх коротких train-записях дал loss 0,00465095 и норму градиента 0,350478; обновление выполнялось только в памяти. Это проверка восстановления, а не новая оценка качества или изменение сдаваемых весов.

Собственная цепочка инициализаций: staging → main на 100 часах → первый batch-128 этап на 464 часах → продолжение 1 → продолжение 2. Между этапами загружались собственные модельные веса и создавался новый optimizer/scheduler. Внутри этапа resume восстанавливает полный checkpoint. Выбранный этап использует AdamW, batch 128, LR 5e-5, warmup 100, горизонт 40 эпох, seed 1, профиль legacy и смещение эпох данных 0. Полный рецепт и все родительские веса сохранены отдельно.

Полная оценка сохранённого кандидата

После выбора модели проверены 13 настроек декодирования на обоих полных dev-наборах: greedy, собственный prefix beam ширины 10/20/50 без LM и с LM weights 0.1/0.2/0.3; word bonus 1, token_topk 8. Минимальный объединённый dev WER 25,64594% дал beam50 + LM 0.1. Настройки зафиксированы в 13:00:47 МСК до запуска test; после просмотра test параметры не менялись.

Полный набор	Записей	WER	CER	Word errors / reference words
dev-clean	2703	13.92596%	4.48214%	7576 / 54402
dev-other	2864	38.16048%	16.24359%	19442 / 50948
test-clean	2620	14.16996%	4.51462%	7450 / 52576
test-other	2939	40.46195%	17.14963%	21179 / 52343

Сравнение декодеров одной модели на полном test (настройки выбраны заранее по dev):

Набор	Greedy WER	Собственный beam50 WER	Beam50 + LM 0.1 WER
test-clean	14.80523%	14.51423%	14.16996%
test-other	41.96359%	41.42292%	40.46195%

Ориентир test-clean ≤20% достигнут; test-other ≤30% не достигнут. В официальной таблице CTC это пороги 7 и 8 баллов за качество соответственно, а не обязательные условия приёма. До бонусов и штрафов текущие метрики достигают уровня 7 баллов. Источник: https://github.com/markovka17/dla/blob/2026/hw1ASR/README.md#quality-score.

Разложение ошибок выбранного декодера проверено по всем предсказаниям; S+D+I точно совпадает с числителем WER:

Набор	Замены S	Пропуски D	Вставки I
dev-clean	6407	542	627
dev-other	16290	1676	1476
test-clean	6247	539	664
test-other	17672	1882	1625

Основная доля ошибок - замены. LM улучшила обе test-метрики относительно собственного beam без LM, но разрыв между clean и other остаётся большим. Выравнивание использует фиксированный порядок diagonal/deletion/insertion; разложение зависит от разрешения равенств, общий WER - нет. Детальные пары ошибок и реальные примеры сохранены в полных логах.

Задача и реализация

Реализован собственный распознаватель английской речи с CTC loss. Проект основан на обязательном шаблоне курса example/asr; история шаблона сохранена в Git. Скачанные акустические модели и сторонние реализации ASR не использовались.

Вход преобразуется в mono 16 кГц и 80 log-Mel полос с окном 25 мс и шагом 10 мс. Две свёртки 3×3 со stride 2 уменьшают временную ось в четыре раза. Далее следуют пять двунаправленных GRU с 512 скрытыми единицами на направление и линейный выход на 29 символов: CTC blank, 26 букв, пробел и апостроф. Модель содержит **24 471 453 параметра**. Для последовательности длины L выходная длина равна ceil(L/4); padding маскируется до свёрток и между ними.

Обучение использует AdamW, LR 3e-4, warmup и cosine decay, clipping 5 и BF16 с вычислением log-softmax и CTC loss в FP32. Записи группируются по длине. Четыре аудиоаугментации: громкость, аддитивный шум, изменение скорости и слабая реверберация. Примеры аудио и спектрограмм сохраняются отдельно.

Данные и выбор модели

Основной корпус - LibriSpeech train-clean-100. Фиксированные train-фрагменты из 96 и 1024 записей позволяют проверить и запустить цепочку до завершения передачи полного корпуса. Источник, идентификаторы и конфигурации каждого запуска сохраняются. Дополнительный train-clean-360 передан, проверен по SHA-256 и распакован в 05:43:45 МСК до cutoff 06:00. Подготовлены 104014 записей (363,61 часа); вместе с train-clean-100 это 132553 записи, 464,20 часа. Полная проверка заголовков и CTC-длин обоих train-наборов не выявила пропусков, дубликатов или невозможных выравниваний. Минимальный запас выходных CTC-шагов равен 6 на train100 и 2 на train360.

Dev-clean и dev-other используются для выбора checkpoint и параметров декодирования. Test-clean и test-other предназначены для однократной итоговой оценки выбранного варианта. Корпусные WER/CER вычисляются как сумма расстояний редактирования, делённая на суммарное число слов/символов эталонов.

Размер батча

На второй H200 измерены forward/backward и шаг AdamW на фиксированных реальных train-записях с BF16: batch 32/64/128/256 даёт 310/495/579/621 записей в секунду и использует 1,83/3,28/6,22/12,12 GiB peak allocated памяти. Измерение включает два прогревочных и восемь учитываемых шагов; загрузка аудио не включена, поэтому это не время полной эпохи. Временные веса замера не используются как модель качества.

Первый этап на 464,20 часа использовал batch 32/LR 1e-4 и отдельный batch 128/LR 3e-4. Продолжение baseline использует batch 128/LR 5e-5. Исправленный кандидат effective_v2 также использует batch 128/LR 5e-5 и другой диапазон эпох данных. Это сравнение конфигураций по dev, а не изолированная абляция размера батча, LR или аугментаций.

Эксперименты и проверки

Проверка	Фактический результат	Значение
Переобучение четырёх реальных train-записей на H200	WER 0, CER 0 на шаге 81	Проверка способности модели обучаться; не оценка обобщения
Пилот: 96 train-записей, 300 шагов	Цепочка обучения завершилась, конечный loss конечен	Проверка логов, checkpoint и инференса
Декодеры пилота, восемь dev-clean записей, одна модель	Greedy: 170/154 словесных ошибок; beam 10: 169/154	Техническая проверка сравнения; непригодно для оценки итогового качества
Проверки кода	Все 80 тестов прошли локально	CTC, beam против полного перебора, padding, метрики, форматы аудио, resume
Чистое окружение без сети и унаследованных пакетов	Установка, pip check, 80 тестов и CPU-инференс четырёх записей прошли	Проверка воспроизводимости окружения; не свежий Colab
Основное обучение	60 эпох на train-clean-100 завершены; с 06:00 обучение на 132553 записях train100+360	По 256 контрольных записей; промежуточные значения
Без аугментаций	8920 шагов: WER dev-clean 38,33%, dev-other 64,79%	Сравнение с аугментациями на том же шаге и тех же записях: clean 35,82% против 38,33% без аугментаций
Предварительный Colab, Tesla T4	Установка, 23 теста, greedy/beam и метрики выполнены	Историческая предварительная проверка; окончательный demo с финальными ресурсами проверен ниже

WER может превышать 100%, поскольку вставки также входят в число ошибок. Значения пилота намеренно не представлены как достижение целевых порогов.

Промежуточная оценка на полных dev-наборах

Сохранённая модель ровно 8920 шагов использована для всех строк ниже. SHA-256: 5c264b2d21e7ea92578de2a9612290fda372602f2b46023ee979e1b0485f38cf. Вероятности закешированы один раз, все декодеры получают одинаковые записи. Это промежуточная модель, а не выбранная финальная сдача.

Набор	Декодер	Записей	WER	CER	Ошибок/слов
dev-clean	greedy	2703	35.73%	11.70%	19437/54402
dev-clean	beam20	2703	34.89%	11.39%	18982/54402
dev-clean	beam20_lm0.1_bonus1.0	2703	33.73%	11.30%	18351/54402
dev-other	greedy	2864	60.75%	26.32%	30950/50948
dev-other	beam20	2864	60.05%	25.91%	30596/50948
dev-other	beam20_lm0.1_bonus1.0	2864	58.87%	25.86%	29993/50948

Beam реализован самостоятельно как CTC prefix search с отдельными вероятностями blank/nonblank в логарифмической области. Внешняя LM - публичная прореженная триграмма OpenSLR, без акустических весов. Для приведённого варианта вес LM равен 0.1, word bonus равен 1.0; более высокие веса 0.3/0.5 ухудшали clean на фиксированном dev-фрагменте. Эти настройки относятся к ранней модели; декодер окончательного checkpoint выбирается отдельно на полных dev-наборах.

Аугментации: 60 эпох на полном dev

Оба запуска имеют одинаковые исходные веса собственного staging-этапа, seed, train-clean-100, batch 32, LR schedule и 53520 шагов обучения. Зафиксированы именно last-модели после 60 эпох; checkpoint не выбирался отдельно для каждой строки. Заданное отличие - включение четырёх аугментаций. В раннем main были исправление CTC-длин и восстановления из checkpoint; сохранённые логи содержат эти перезапуски. Поэтому сравнение описывает две полученные траектории с одним seed, а не изолированный вклад каждой аугментации. Оценены все 2703 записи dev-clean и 2864 dev-other с greedy.

Набор	С аугментациями WER	Без аугментаций WER	С аугментациями CER	Без аугментаций CER
dev-clean	24.45%	28.82%	7.98%	9.89%
dev-other	51.38%	57.89%	22.21%	26.06%

Аугментации снизили WER на 4,37 процентного пункта для clean и 6,51 для other. Это результат двух конкретных запусков с одним seed; оценка вариативности между seed не проводилась. Хеши моделей, конфигурации, транскрипции и суммы ошибок сохранены в ablation-60epoch и локальных JSON-результатах. Эти dev-результаты не подменяют итоговую оценку выбранной модели на test.

Структура ошибок промежуточной модели

Для той же last-модели после 60 эпох выполнено словесное выравнивание всех dev-предсказаний. Суммы замен, пропусков и вставок точно совпали с числителем корпусного WER.

Набор	Замены	Пропуски	Вставки	Всего ошибок / слов
dev-clean	11145	1055	1101	13301 / 54402

Набор	Замены	Пропуски	Вставки	Всего ошибок / слов
dev-other	22005	2236	1936	26177 / 50948

Около 84% словесных ошибок составляют замены. Среди частых пар встречаются in → and и and → in; часты вставки и пропуски коротких служебных слов. Это абсолютные частоты, а не вероятность ошибки для данного слова: для такого вывода нужна нормировка на число его употреблений. В отдельных записях видны ошибки границ слов (inevitable → in evitable) и орфографии; на other встречаются длинные сильно искажённые фрагменты. Эти наблюдения относятся к сохранённым dev-предсказаниям, а не к оценке причин по прослушиванию. На графиках показана норма градиента до clipping; большие отдельные значения не означают отмену порога 5.

При равных минимальных расстояниях выбран порядок diagonal/deletion/insertion; разложение S/D/I зависит от разрешения таких равенств, общий WER - нет. Скрипт scripts/analyze_errors.py сохраняет частые пары и пять примеров с наибольшим абсолютным числом словесных ошибок (UID разрешает равенства). Анализ выбранной модели приведён выше и сохранён отдельно в итоговых логах.

Последний промежуточный снимок декодирования

Снимок основной модели сохранён на шаге 42816 (эпоха 47), SHA-256 9c9cc9ec7d63d5d951e5a931af305dd583b38507945c4c705376d413a8ca8d48. Проверены 13 настроек на 256 случайных записях каждого dev-набора с seed 42. Это отдельный фиксированный поднабор, отличающийся от мониторинга обучения с seed 1; строки относятся к одним и тем же вероятностям снимка.

Набор	Greedy WER	Beam10 WER	Beam10 + LM 0.2 WER	CER с LM
dev-clean, 256 записей	25.81%	25.34%	24.50%	8.05%
dev-other, 256 записей	51.73%	51.47%	49.90%	22.32%

Word bonus равен 1.0. Для этого поднабора минимальный суммарный корпусный WER дала ширина 10 с весом LM 0.2. Это предварительная проверка; окончательный декодер выбирается заново на обоих полных dev-наборах после фиксации модели. Test-наборы здесь не использовались.

Обнаруженные ошибки и исправления

Первый диагностический контейнер не предоставлял CUDA, поэтому проверка шла на CPU. Для отдельного учебного контейнера применён режим, при котором доступ к обеим H200 подтверждён реальным вычислением. Остальные сервисы и Xorg не изменялись; аппаратный reset не требовался для обучения.

Ревью выявило потерю накопленных градиентов в checkpoint между шагами оптимизатора. Теперь checkpoint сохраняет сами градиенты и число обработанных microbatch. Регрессионный тест сравнивает следующий шаг непрерывного и восстановленного обучения с dropout и частичным накоплением: параметры и следующий RNG draw совпадают точно. Аугментации детерминированы по seed, эпохе и индексу записи; DataLoader использует отдельный генератор. При изменении batch после OOM текущая эпоха явно начинается заново. При исключении

сохраняется последний исправный checkpoint, а не повреждённое состояние.

При изменении скорости одна быстрая запись получала 162 выходных шага при необходимых 164, и обучение явно остановилось. Проверка всех исходных 28 539 записей не выявила невыполнимых выравниваний. Минимальная длина ускоренной записи теперь ограничена длиной текста с учётом повторяющихся символов; отдельный тест воспроизводит проблему и проверяет исправление. Обучение восстановлено из исправного checkpoint и прошло проблемный шаг.

Управление этапами исправлено отдельно: повторное resume уже законченных 60 эпох больше не используется как продолжение кампании. Если первый этап заканчивается раньше 06:00, запускается refinement с новым scheduler. После 06:00 запускается новый этап на 460 или 100 часах, ограниченный 12:30; инициализация выбирается по dev среди сохранённых основных кандидатов. Тесты проверяют продолжение и строгое время готовности дополнительных данных.

Независимый контроллер итоговой оценки стартовал после 12:30 и завершился в 13:06:31 МСК. Он рассматривает best и last каждого основного этапа, проверяет соответствующие full checkpoint и оценивает одинаковые model-файлы по SHA-256 один раз. Checkpoint выбирается по суммарным word errors, делённым на суммарное число reference words обоих полных dev-наборов. При равенстве используются dev-clean, dev-other и имя кандидата. Декодер выбирается по той же объединённой корпусной метрике обоих полных dev-наборов. До этой фиксации test не оценивается. Проверяется совпадение всех тензоров и состояния модели с полным resume-checkpoint. Ревью выявило неатомарную запись снимков и кешей; прерывание теперь восстанавливается через проверку файла и повторное построение, записи завершаются атомарным переименованием.

Для обучения на 460 часах выделено отдельное окно 06:00-12:30. Если дополнительный корпус не готов вовремя, основное обучение на 100 часах продолжается. Сбой W&B не останавливает запись локальных JSONL.

Аудит аугментаций и сохранность результатов

Аудит обнаружил, что постоянный множитель громкости почти полностью устраняется нормализацией log-Mel. На 12 реальных train-примерах RMS-разность признаков составляла 1,7-2,5e-6. Исходная реверберация также давала слабый эффект. Этот режим сохранён под именем legacy для точного воспроизведения прежних запусков.

Отдельный кандидат effective_v2 использует плавную огибающую громкости с пятью узлами и реверберацию с контролируемой энергией отражённого сигнала. Noise, speed и защита CTC-длин сохранены. Проверка на четырёх train-FLAC и трёх seed дала RMS-разность log-Mel 0,0307-0,0988 для громкости и 0,0744-0,1617 для реверберации; значения конечны. Это подтверждает действие преобразований, но не улучшение WER. Новый режим выбирается для сдачи только по полным dev-наборам. Смещение эпох данных 80 предотвращает повторение прежнего порядка данных; контрольные dev-поднаборы сохраняют seed 1.

Перед изменением числа тренеров создан полный серверный снимок: 76399 логических файлов, 55117 уникальных содержимых, 23 согласованные пары model/full checkpoint, четыре TAR общим размером 10329907200 байт. Копии на E полностью проверены по SHA-256 архивов и каждого содержимого; все 23 пары повторно загружены и сравнены по тензорам и состоянию. Для batch-32 сохранены дополнительные свежие снимки и окончательный закрытый запуск: 40 эпох, 165720 шагов, штатный train_exit в 12:06:46 МСК. После проверенных резервов отключено только его автоматическое продолжение; сам тренер закончил работу естественно. Оба batch-128 кандидата завершились по cutoff около 12:30; их окончательные веса, full checkpoint и закрытые

логи также скопированы и проверены на E. Исходники с полной историей Git также сохраняются на ГМЦ и E; восстановление bundle подтвердило commit 360563d8fa44024d1965ababd7898726de956b66 и исходного предка шаблона. Эти резервы не заменяют окончательный комплект сдачи.

Воспроизведение

Команды установки, обучения, возобновления, инференса и расчёта метрик приведены в README. Каждый запуск сохраняет config.json, train_manifest.json, metrics.jsonl, offline W&B, best/last checkpoint и модель для безопасной загрузки weights_only=True. scripts/evaluate_decoders.py сохраняет вероятности одной модели и сравнивает greedy с собственным prefix beam на одинаковых записях.

Выбранный checkpoint, SHA-256, конфигурация и полные dev/test метрики приведены выше. Чистая установка из архива и свежий Colab проверены для сохранённого кандидата; окончательная упаковка и проверка восстановления архива продолжаются.

Проверка сохранённого комплекта

Исходный архив commit cb39bb37233495cc27eec1a424a072d0c6c091de (669026 байт, SHA-256 00ae68b0145abb9107a3b5950b66921c0c9aa46d18f857172d29b3cd5b7de9b9) распакован в отдельный каталог. В ранее созданном изолированном clean-env повторены установка requirements без внешней сети, pip check, все 80 тестов (3,49 с), инференс выбранной модели с эталоном и без него, один шаг обучения и полный resume до следующего шага. Все восемь команд завершились с кодом 0. Это повторная проверка нового исходного архива в изолированном окружении, а не утверждение о повторном создании venv с нуля.

Итоговый demo проверен в новом Colab runtime: Python 3.13.15, PyTorch 2.11.0+cu130, Tesla T4. До дедлайна репозиторий приватный, поэтому собственный source ZIP загружен через Files, SHA-256 проверен и исходники распакованы в /content/DLA-ASR-2026. Подготовительная ячейка удалена перед Run All. Все 12 исходных ячеек (шесть кодовых) выполнены без ошибок; единственное изменённое значение - пользовательский DATASET_URL. Это не доказательство анонимного клонирования приватного репозитория.

С эталоном пользовательский train-пример дал 3 ошибки на 36 словах (WER 8,3333%), 2 ошибки на 178 символах. Это проверка интерфейса на обучающем примере, а не оценка обобщения. Затем через обычный ввод того же поля задан новый архив без эталонов: FLAC mono16k, WAV stereo8k, MP3 stereo44.1k. Повторный Run All сохранил ровно ID original-16k, stereo-8k, stereo-44k; metrics=null, metrics.json отсутствует, каталог предсказаний новый, ID прошлого набора отсутствует. Выполненные notebook и ZIP предсказаний сохранены отдельно для обоих запусков.

При подготовке вложенный files.upload не открыл chooser: операция отменена, штатная панель Files успешно загрузила архив. Автоматическое DOM-fill поля показало новый URL, но не обновило код Colab; обычный клавиатурный ввод и выход из поля обновили код, что проверено до успешного повторного запуска. Промежуточный повтор прежнего набора не используется как доказательство проверки без эталонов.

Все закрытые логи первой кампании от начала обучения сохранены: 257452 файла, 1097019660 исходных байт. ZIP 707817314 байт, SHA-256 fcaee6a15e80133e4c27bd72267ce14f9b4ab3928d53495eecda93dcedaa3e8d. SHA-256 и размер каждого члена проверены по манифесту исходного захвата. Распознаваемых паттернов токенов/приватных ключей не найдено; это ограниченная эвристическая проверка. Оригинальный ZIP загружен через Drive UI после ограничений connector, затем полностью скачан

без cookies с совпадением SHA-256. Веса и пример также скачаны анонимно с проверкой хешей. Дополнительные обучающиеся этапы в этот закрытый архив не входят и сохраняются отдельно.

Ресурсы: https://drive.google.com/drive/folders/1zEsNRMJbv4HlCOPf6mflxe9-GnWjo3pe . Скрипт scripts/download_resources.py загружает модель, пример, официальную LM и полный ZIP логов; URL и SHA-256 находятся в resources.json. Полные логи не распаковываются в Colab автоматически, чтобы не создавать сотни тысяч файлов.

Ограничения

Измеренный test-clean WER 14,17% соответствует ориентиру ≤20%; test-other WER 40,46% превышает ориентир ≤30%. Окончательный notebook с сохранённым checkpoint прошёл полный запуск в свежем Colab T4; подробности приёмки приведены ниже. Репозиторий должен оставаться приватным до дедлайна. Правила курса запрещают LLM: техническая готовность этой работы не подтверждает соответствие этому правилу.

Кривые из локальных журналов

Источник: finetune460\metrics.jsonl, lr_candidate_augmented460\metrics.jsonl, lr_candidate_finetune460\metrics.jsonl, lr_candidate_finetune460_continue1\metrics.jsonl, lr_candidate_finetune460_continue2\metrics.jsonl, main\metrics.jsonl, no_aug\metrics.jsonl, refine100\metrics.jsonl. Только измеренные значения; пилотные запуски не заменяют итоговую оценку.

