HW1 ASR - проверенный промежуточный результат

Состояние на 13 октября 2026 года, 18:00 МСК. Этот документ относится только к сохранённой модели e640. Дополнительное обучение на смеси clean/other продолжается до 20:40 МСК; его результаты сюда не включены. Прежний комплект baseline сохранён отдельно. Окончательная сдача состоится после проверки выбранного кандидата.

Модель, данные и обучение

Собственная DeepSpeech2-подобная CTC-модель содержит 24 471 453 параметра: две свёртки, пять двунаправленных GRU по 512 единиц на направление и линейный выход. Вход - mono 16 кГц, 80 log-Mel полос, окно 25 мс, шаг 10 мс. Алфавит: 26 букв, пробел, апостроф, CTC blank. Длины после свёрток вычисляются явно; CTC loss считается в FP32 при BF16 forward.

До фиксации e640 использовались только train-clean-100 и train-clean-360, суммарно 464,196 часа. Dev-clean и dev-other служили для выбора модели и декодера. Test не использовался для обучения и настройки. Собственная цепочка родителей начинается с обучения staging с нуля и продолжается этапами на clean; внешний акустический checkpoint не применялся. Полная ранняя цепочка описана в REPRODUCTION.md и сохранена в initializations.zip.

Выбран lr_candidate_extension1326_effective_v2, последний checkpoint: step 34937, epoch 33, batch_index 749. Его родитель - собственная модель d919, уже оценённая в первой кампании. На новом этапе создан новый optimizer/scheduler: AdamW, batch 128, LR 2e-5, weight decay 1e-4, warmup 100 шагов, cosine с горизонтом 40 эпох, clipping 5, seed 1, data_epoch_offset 120. Обучение штатно завершено по календарному cutoff 15:25 МСК. valid_limit=256 относится только к промежуточному мониторингу; итоговый выбор выполнен по полным dev-наборам.

Профиль effective_v2 содержит четыре аудиоаугментации: громкость с плавной огибающей, шум, скорость и слабую контролируемую реверберацию. Исходные и преобразованные WAV/спектрограммы сохранены отдельно. Legacy-режим и его результаты сохранены для сравнения.

Выбор до итогового test

Рассмотрены best и last десяти завершённых запусков; одинаковые model-only SHA учитывались один раз. По утверждённому пользователем правилу выбирался минимальный корпусный greedy WER полного dev-other среди моделей с полным dev-clean WER не выше 20%; при равенстве - dev-clean и имя. Для выбранной модели greedy даёт 14,31014% на dev-clean и 39,21253% на dev-other.

Затем на обоих полных dev-наборах проверены 13 настроек: greedy; собственный prefix beam ширины 10/20/50; те же beam с LM weights 0.1/0.2/0.3, word bonus 1 и token_topk 8. Выбран beam10 + LM 0.2 по dev-other с ограничением clean. Модель и декодер зафиксированы до запуска test. Настройки после test не менялись.

Полные измеренные результаты

Таблица автоматически сверяется с INTERMEDIATE_RESULTS.json: WER = сумма word errors / сумма reference words, CER аналогично по символам. Значения поднабора dev256 сюда не входят.

Набор	Записей	WER	CER	Word errors / reference words
dev-clean	2703	13.72744%	4.42528%	7468 / 54402
dev-other	2864	37.57949%	16.19847%	19146 / 50948
test-clean	2620	13.97976%	4.48300%	7350 / 52576
test-other	2939	39.88499%	17.13937%	20877 / 52343

На одной и той же замороженной модели собственный beam10 без LM улучшает полный test-clean с 14,55227% greedy до 14,20230%, test-other - с 41,42101% до 41,04465%. Добавление заранее выбранной LM даёт значения основной таблицы. Относительно сохранённого baseline test-other снизился с 40,46195% до 39,88499%; это сравнение результатов после dev-выбора, а не правило отбора по test.

Проверка и ресурсы

Model-only: 97 898 508 байт, SHA-256 e640a13abfc720cbdbaa3617edee386138cd4f9b7c78e9d191319e57d6e90f77. Соответствующий full checkpoint: SHA-256 9ed809fb5ff6a5848056f5d2f996032f1b1423b21b560a36e1f34c89783ad8e5. На ГМЦ и E проверены хеши, все тензоры и состояние model/full; восстановлены AdamW, scheduler, Python/NumPy/Torch/CUDA RNG и градиенты. Диагностический FP32 CPU-шаг дал конечные loss 0,001730732 и gradient norm 0,0877893; сдаваемые веса не изменялись.

Свежий Colab T4 выполнен с исходными 12 ячейками, с эталонами и без них. Источники загружены приватным ZIP с проверенным SHA; перед подготовкой папка проекта отсутствовала. Модель/пример/LM/логи скачивались по URL с SHA. В наборе с эталоном получено 3 ошибки на 36 словах одного обучающего примера - это проверка интерфейса, не test-метрика. Второй запуск создал отдельный каталог и ровно три исходных ID для WAV/FLAC/MP3, разных sample rate и stereo; metrics=null, устаревших предсказаний нет. Исполненные notebook, ZIP и проверки сохранены в acceptance-e640.zip.

Текущая версия добавляет только опцию выбора best по dev-other в новых обучающих этапах; старое поведение по умолчанию сохранено. 94 теста пройдены локально и в изолированном окружении ГМЦ, включая реальную проверку выбора best при противоположной динамике clean/other. Полные dev/test сравнения и предсказания сохранены отдельно в evaluation-e640.tar.gz: 111383 файла, каждый SHA проверен. Полные логи ранних и дополнительных этапов, родительские веса, full resume, исходники и Git bundle включаются в отдельный промежуточный архив с манифестом SHA-256.

Ресурсы этого кандидата находятся в INTERMEDIATE_RESOURCES.json; canonical baseline resources.json не подменяется молча. Для загрузки используйте scripts/download_resources.py --manifest INTERMEDIATE_RESOURCES.json. Внешняя LM - официальная LibriSpeech 3-gram из OpenSLR 11; она не является акустической моделью.

Ограничения и продолжающееся обучение

Порог test-clean WER ≤20% достигнут; test-other ≤30% не достигнут. Эти значения - уровни таблицы качества курса, а не самостоятельная гарантия итоговой оценки. Публикация приватного исходного репозитория и анонимный clone пока не пройдены; готовый Git bundle предусмотрен как согласованный пользователем резервный способ передачи.

Для следующих кандидатов добавлены 100,1166 часа train-other-500: первые полные главы в порядке официального архива, не случайная выборка. Полный исходный архив 500 часов не скачан и не проверен целиком. Все отобранные записи, тексты, SHA, CTC-длины и отсутствие пересечения с clean/dev/test проверены. На одной GPU обучается смесь всех 464,196 часов clean и этого other-поднабора с повторениями; вторая GPU остаётся clean-контролем. Эти эксперименты будут оценены отдельно после 20:40 по полному dev-other с ограничением dev-clean ≤20%, затем по замороженным настройкам на test.

Правила курса запрещают использование LLM. Работа подготовлена с AI-помощью; техническая воспроизводимость не подтверждает соответствие этому правилу. Ограничение раскрыто явно.